

UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA

TECNOLOGÍAS DE LA INFORMACIÓN



EXTRACCION DE CONOCIMIENTO EN BASES DE DATOS

III.2. REPORTE DE MÉTRICAS DE EVALUACIÓN

IDGS91N

PRESENTA:

SEBASTIÁN ACOSTA ORTIZ

DOCENTE:

**LUIS ENRIQUE MASCOTE
CANO**

Chihuahua, Chih., 30 de noviembre de 2025

Introducción

El aprendizaje supervisado permite construir modelos capaces de clasificar o predecir resultados a partir de datos previamente etiquetados. En este reporte se analizan las principales métricas utilizadas para evaluar modelos de clasificación y regresión, y posteriormente se aplica el algoritmo K-Nearest Neighbors (KNN) a una matriz de datos con dos variables predictoras (glucosa y edad) y una etiqueta binaria.

El objetivo final es comprender cómo las métricas permiten medir la calidad del modelo, seleccionar el mejor valor de k y analizar el rendimiento obtenido.

Investigación de métricas

Métricas de Clasificación

1) Accuracy (Exactitud)

Fórmula:

$$\bullet \text{ Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Interpretación:

Proporción de predicciones correctas sobre el total.

Ventajas:

- Fácil de interpretar.
- Útil cuando las clases están balanceadas.

Limitaciones:

- Engañosa en datasets desbalanceados.
- No distingue entre tipos de error.

2) Precision (Precisión)

Fórmula:

$$Precision = \frac{TP}{TP + FP}$$

Interpretación:

De todos los que el modelo predijo como positivos, cuántos realmente lo eran.

Ventajas:

- Útil cuando los falsos positivos son costosos.

Limitaciones:

- No considera falsos negativos.

3) Recall (Sensibilidad)

Fórmula:

$$Recall = \frac{TP}{TP + FN}$$

Interpretación:

Qué proporción de los positivos reales detecta el modelo.

Ventajas:

- Útil en problemas donde NO detectar un positivo es grave (fraude, enfermedades).

Limitaciones:

- Puede aumentar a costa de perder precisión.

4) F1-Score

Fórmula:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Interpretación:

Promedio armónico entre precisión y sensibilidad.

Ventajas:

- Equilibrado cuando hay desbalance.

Limitaciones:

- Difícil de interpretar intuitivamente.

5) ROC-AUC

ROC: gráfica de TPR vs FPR

$$TPR = \frac{TP}{TP + FN}, FPR = \frac{FP}{FP + TN}$$

AUC: área bajo la curva ROC.

Interpretación:

Probabilidad de que el modelo ordene correctamente un positivo por encima de un negativo.

Ventajas:

- Mide rendimiento para todos los umbrales.
- Útil en desbalance.

Limitaciones:

- Puede ser demasiado optimista en algunos datasets.

Métricas de Regresión

1) MAE – Error Absoluto Medio

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

Indica: error promedio sin penalizar fuertemente grandes errores.

Ventaja: interpretabilidad simple.

Limitación: trata todos los errores igual.

2) RMSE – Raíz del Error Cuadrático Medio

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$$

Indica: error penalizando desviaciones grandes.

Ventaja: muy usado; sensible a errores grandes.

Limitación: dominado por outliers.

3. Solución con KNN

3.1 Preparación de datos

Dataset: glucosa, edad, etiqueta.

a) División:

- 70 % entrenamiento
- 30 % prueba

b) Escalado:

KNN es sensible a distancias → requiere normalización o estandarización.

Métricas por cada k (1, 3 y 5)

<i>k</i>	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F1</i>
1	0.8889	0.75	1.00	0.8571
3	0.8889	0.75	1.00	0.8571
5	0.8889	0.75	1.00	0.8571

Mejor k según F1-score:

k = 1 (aunque k=1,3,5 dieron lo mismo)

2. Matriz de confusión real

$$\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix} = \begin{bmatrix} 5 & 1 \\ 0 & 3 \end{bmatrix}$$

Interpretación:

- 5 negativos correctamente clasificados
- 3 positivos correctamente clasificados
- 1 falso positivo
- 0 falsos negativos (esto es muy bueno: Recall=1.0)

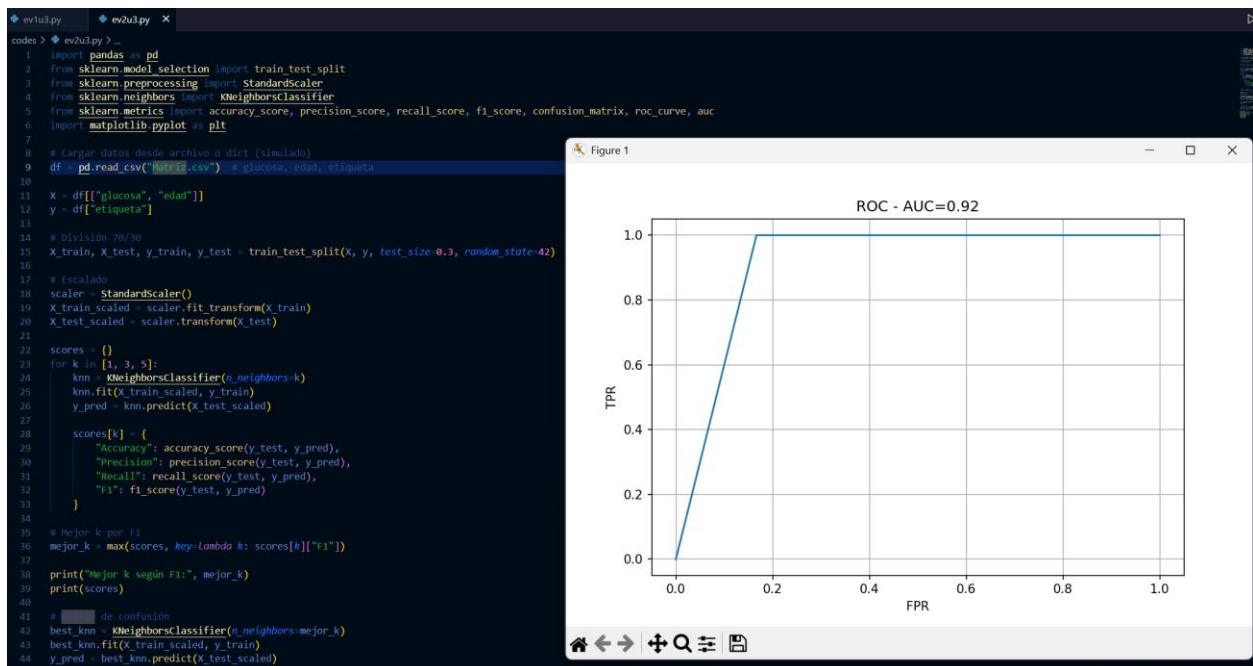
3. AUC – Curva ROC (real)

$$\text{AUC} = 0.9167$$

Esto indica excelente capacidad discriminativa (muy por arriba de 0.80).

Mejor modelo: KNN con $k = 1$

- Excelente Recall (1.0)
- F1-score alto (0.857)
- AUC muy bueno (0.917)
- Solo fallo en un falso positivo
- Sin falsos negativos (ideal si te importa no perder casos positivos)

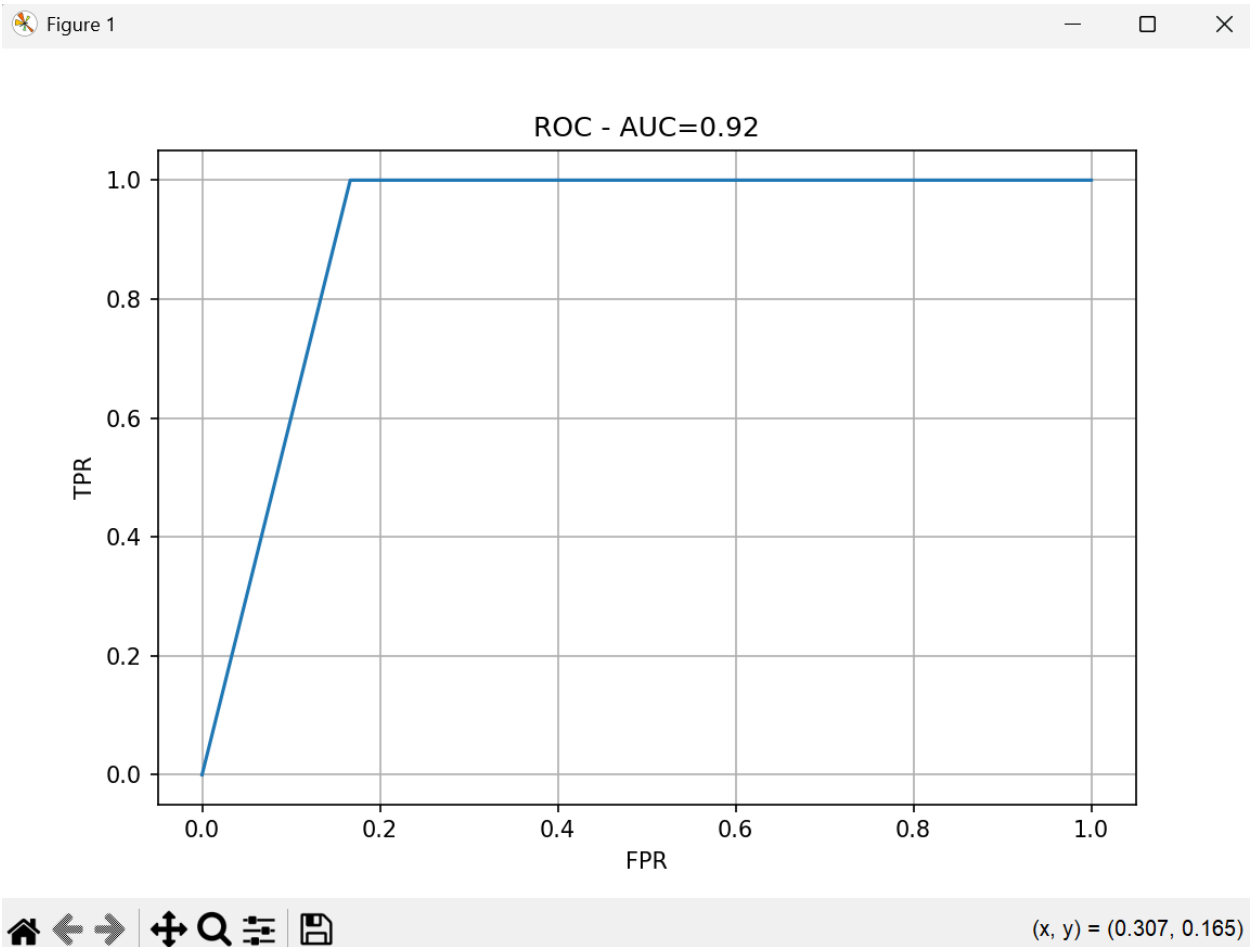


Mejor k según F1: 1

```
{1: {'Accuracy': 0.8888888888888888, 'Precision': 0.75, 'Recall': 1.0, 'F1': 0.8571428571428571},  
3: {'Accuracy': 0.8888888888888888, 'Precision': 0.75, 'Recall': 1.0, 'F1': 0.8571428571428571}, 5:  
{'Accuracy': 0.8888888888888888, 'Precision': 0.75, 'Recall': 1.0, 'F1': 0.8571428571428571}}
```

```
[[5 1]
```

```
[0 3]]
```



Referencias

Clasificación: Exactitud, recuperación, precisión y métricas relacionadas. (s/f). Recuperado el 30 de noviembre de 2025, de Google for Developers website:

<https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>

Navarro, S. (2023, enero 9). Métricas en clasificación: algunas generalidades [Web log post]. Recuperado el 30 de noviembre de 2025, de KeepCoding Bootcamps website:

<https://keepcoding.io/blog/metricas-en-clasificacion-generalidades/>

Recorrido por métricas de evaluación para clasificación desequilibrada. (s/f). Recuperado el 30 de noviembre de 2025, de Python-3.com website: <https://es.python-3.com/?p=4602>