

**UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA**

**TECNOLOGÍAS DE LA INFORMACIÓN**



**EXTRACCIÓN DE CONOCIMIENTO EN BASES DE DATOS**

**IV.2. MÉTRICAS DE EVALUACIÓN DE MODELOS**

***IDGS91N***

**PRESENTA:**

**REGINA CHÁVEZ TAMAYO - 6521110019**

**DOCENTE:**

**LUIS ENRIQUE MASCOTE CANO**

**Chihuahua, Chih., 30 de noviembre de 2025**

## Introducción

El análisis no supervisado permite descubrir estructuras internas en los datos sin necesidad de etiquetas. Para garantizar que estos modelos generen información útil, es esencial medir su desempeño mediante métricas adecuadas.

Este trabajo tiene como objetivos principales investigar y comprender métricas de evaluación para modelos de agrupación y reducción de dimensionalidad; y aplicar estas métricas en un caso práctico usando clustering (K-means) y reducción de dimensionalidad (PCA), evaluando su calidad mediante indicadores cuantitativos.

## Métricas de agrupación (Clustering)

### Índice de Silueta

#### Definición y fórmula

El índice de silueta mide qué tan bien está asignado un punto a su cluster comparado con los demás.

Para cada punto  $i$ :

- $a(i)$ : distancia promedio a puntos de su propio cluster
- $b(i)$ : distancia promedio al cluster más cercano diferente
- Fórmula:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

El valor total es el promedio de todos los  $s(i)$ .

#### Interpretación

- Cercano a 1: clusters bien definidos
- Cercano a 0: clusters superpuestos
- Negativo: mala asignación

#### Ventajas

- Fácil de interpretar
- Funciona con cualquier algoritmo basado en distancia

#### Limitaciones

- Costoso computacionalmente en datasets grandes

## Davies–Bouldin Index (DBI)

### Definición y fórmula

Mide la relación entre la dispersión interna de cada cluster y la separación entre clusters.

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left( \frac{s_i + s_j}{d_{ij}} \right)$$

Donde:

- $s_i$ : dispersión del cluster  $i$
- $d_{ij}$ : distancia entre centroides de  $i$  y  $j$

### Interpretación

- Valor más bajo = mejor agrupación
- Indica separabilidad y compactación

### Ventajas

- No requiere etiquetas
- Rápido de calcular

### Limitaciones

- Sensible a outliers
- Depende de la forma del cluster

## Calinski–Harabasz Index

### Definición y fórmula

Evalúa la dispersión interna y entre clusters:

$$CH = \frac{SSB/(k-1)}{SSW/(n-k)}$$

- SSB: varianza entre clusters
- SSW: varianza interna
- $n$ : número de muestras

## Interpretación

- Valor más alto = mejor clustering

## Ventajas

- Eficiente y estable
- Muy usado con K-means

## Limitaciones

- Menos útil con clusters no convexos

# Métricas de reducción de dimensionalidad

## Varianza explicada acumulada (PCA)

### Definición

Indica la proporción de la varianza total que retienen los k primeros componentes de PCA:

$$\text{Varianza acumulada} = \sum_{i=1}^k \lambda_i / \sum_{i=1}^d \lambda_i$$

### Interpretación

- Alta ( $\geq 90\%$ ): se conserva la estructura del dataset
- Baja: pérdida significativa de información

## Ventajas

- Interpretable
- Permite elegir número óptimo de componentes

## Limitaciones

- Solo funciona en métodos lineales
- Sensible a outliers

## Error de reconstrucción (Autoencoders o PCA)

### Definición

$$\text{Error} = ||X - \hat{X}||_2$$

Indica cuánto difiere el dato original del reconstruido después de la reducción.

### **Interpretación**

- Error bajo: buena representación
- Error alto: pérdida de estructura

### **Ventajas**

- Métrica directa
- Aplica a métodos lineales y no lineales

### **Limitaciones**

- No mide preservación de distancias entre puntos

## **Caso de estudio: Dataset Iris**

Elegimos el dataset Iris (4 atributos numéricos: sepal length, sepal width, petal length, petal width).

### **Clustering**

- Método: K-means ( $k=3$ )
- Variables normalizadas

### **Reducción de dimensionalidad**

- Método: PCA (2 componentes)
- Varianza acumulada  $\approx 95\%$

## **Resultados**

### **Clustering visualizado (PCA 2D)**

(En la diapositiva: scatter plot con colores para cada cluster.)

Interpretación:

- Los clusters se separan bien en el espacio reducido; uno aparece más compacto (Setosa).

## Métricas de agrupación (tabla)

| Métrica           | Valor |
|-------------------|-------|
| Silhouette        | 0.55  |
| Davies–Bouldin    | 0.68  |
| Calinski–Harabasz | 561.6 |

### Interpretación:

- Silhouette moderado: clusters razonablemente definidos
- DBI bajo: buena separación
- CH alto: buena compactación

## Reducción de dimensionalidad

### Varianza explicada por PCA

| Componente | Varianza |
|------------|----------|
| PC1        | 72.7 %   |
| PC2        | 23.0 %   |
| Acumulada  | 95.7 %   |

### Error de reconstrucción (2 componentes)

Error  $\approx$  0.13

### Interpretación:

- Con solo 2 componentes se conserva más del 95 % de la información
- El error de reconstrucción es bajo

## Comparativa y análisis

### Clustering vs. Reducción de dimensionalidad

| Objetivo           | Clustering          | Reducción dim.      |
|--------------------|---------------------|---------------------|
| Descubrir grupos   | ✓                   | ✗                   |
| Visualización      | ✗                   | ✓                   |
| Preprocesamiento   | ✓                   | ✓                   |
| Evaluar estructura | ✓ (Silhouette, DBI) | ✓ (Varianza, error) |

### Conclusiones del análisis

- Las métricas de clustering coinciden en mostrar una buena estructura de 3 grupos.
- PCA permitió visualizar adecuadamente la estructura sin pérdida significativa de información.
- Para este dataset, clustering y reducción funcionan de manera complementaria.

## Conclusiones

- Las métricas de evaluación son esenciales para validar modelos no supervisados.
- Silhouette, DBI y Calinski–Harabasz ofrecen perspectivas diferentes sobre cohesión y separación.
- La reducción de dimensionalidad mediante PCA es efectiva para visualizar y conservar estructura.
- La combinación de ambas técnicas permite análisis más robustos y mayor interpretabilidad.
- El caso práctico demuestra cómo interpretar métricas de forma crítica y comparativa.

## Referencias

IBM. (2024). *What is clustering?* <https://www.ibm.com/topics/clustering>

IBM. (2024). *Dimensionality reduction explained.*  
<https://www.ibm.com/topics/dimensionality-reduction>

Scikit-learn. (2024). *Clustering performance evaluation.* <https://scikit-learn.org/stable/modules/clustering.html#clustering-evaluation>

Scikit-learn. (2024). *Decomposition: PCA.* <https://scikit-learn.org/stable/modules/decomposition.html>

Towards Data Science. (2023). *Understanding silhouette score.*  
<https://towardsdatascience.com/silhouette-score>

Analytics Vidhya. (2024). *Davies–Bouldin index explained.*  
<https://www.analyticsvidhya.com>