

# **UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA**

## **DESARROLLO Y GESTIÓN DE SOFTWARE**



### **IV.2. Métricas de evaluación de modelos**

#### **EXTRACCIÓN DE CONOCIMIENTO EN BASES DE DATOS**

**PRESENTA:**

**KARLA ALEJANDRA DE LA CRUZ ZEA**

**DOCENTE:**

**ING. LUIS ENRIQUE MASCOTE CANO**

29 de noviembre de 2025

# Contenido

Introducción .....	2
Investigación de métricas.....	2
Métricas de Agrupación.....	2
Índice de Silueta .....	2
Davies–Bouldin Index (DBI) .....	3
Calinski–Harabasz Index (CH) .....	3
Métricas de Reducción de Dimensionalidad .....	3
Varianza explicada acumulada (PCA) .....	3
Error de reconstrucción (Autoencoders o PCA) .....	4
Caso de estudio y aplicación práctica .....	4
Clustering con K-Means .....	4
Cálculo de métricas.....	5
Reducción de dimensionalidad con PCA .....	5
Implementación .....	5
Resultados.....	6
Conclusión .....	6

## Introducción

La evaluación de modelos no supervisados es esencial para validar la calidad de los resultados en tareas de clustering y reducción de dimensionalidad. A diferencia del aprendizaje supervisado, donde se dispone de etiquetas, los modelos no supervisados requieren métricas internas que midan cohesión, separación, reconstrucción o preservación de estructura.

El objetivo de este reporte es estudiar métricas relevantes de ambos enfoques y aplicarlas en un caso práctico utilizando un conjunto de datos real. Se mostrarán gráficas, tablas y análisis comparativo.

## Investigación de métricas

### Métricas de Agrupación

#### Índice de Silueta

##### Definición:

Mide qué tan bien un punto está asignado a su cluster en comparación con otros clusters.

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Donde:

- $a(i)$ : distancia promedio del punto a su propio cluster.
- $b(i)$ : distancia promedio al cluster más cercano.

##### Interpretación:

- **Cerca de 1:** buena separación y cohesión.
- **Cerca de 0:** fronteras entre clusters.
- **Negativo:** mala asignación.

**Ventajas:** intuitivo, fácil de interpretar.

**Limitaciones:** no funciona bien con clusters no convexos.

### Davies–Bouldin Index (DBI)

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left( \frac{s_i + s_j}{d_{ij}} \right)$$

Donde:

- $s_i$ : dispersión interna.
- $d_{ij}$ : distancia entre centroides.

**Interpretación:**

- **Más bajo = mejor clustering.**

**Ventajas:** considera separación y cohesión.

**Limitaciones:** sensible a ruido.

### Calinski–Harabasz Index (CH)

$$CH = \frac{\text{Var entre clusters}}{\text{Var dentro de clusters}}$$

**Interpretación:**

- **Más alto = mejor agrupación.**

**Ventajas:** rápido y estable.

**Limitaciones:** favorece clusters esféricos.

### Métricas de Reducción de Dimensionalidad

#### Varianza explicada acumulada (PCA)

$$\text{Varianza explicada} = \frac{\lambda_i}{\sum \lambda}$$

**Interpretación:**

Qué porcentaje de la información original conserva cada componente.

- **Alto:** buena representación.
- **Bajo:** pérdida de información.

**Ventajas:** cuantitativa y fácil de comparar.

**Limitaciones:** solo capta relaciones lineales.

**Error de reconstrucción (Autoencoders o PCA)**

$$E = ||X - \hat{X}||^2$$

**Interpretación:**

- **Bajo error:** buena representación comprimida.
- **Alto error:** mala reconstrucción.

**Ventajas:** útil cuando queremos reconstruir datos.

**Limitaciones:** depende de la escala.

**Caso de estudio y aplicación práctica****Dataset elegido: *Iris***

- 150 muestras
- 4 atributos numéricos: *sepal length*, *sepal width*, *petal length*, *petal width*
- 3 especies (solo se usarán para visualizar, no para evaluar clustering)

**Clustering con K-Means**

Se aplicó K-Means con **k = 3**.

## Cálculo de métricas

<i><b>Métrica</b></i>	<b>Valor</b>
<i>Silhouette</i>	<b>0.58</b>
<i>Davies–Bouldin</i>	<b>0.63</b>
<i>Calinski–Harabasz</i>	<b>425.1</b>

## Reducción de dimensionalidad con PCA

Se redujo de 4 dimensiones a 2 para visualizar los clusters.

<b>Componente</b>	<b>Varianza</b>
<b>PC1</b>	72.9%
<b>PC2</b>	22.8%
<b>Total 2D:</b>	<b>95.7%</b>

## Implementación

Python

```
1 from sklearn.datasets import load_iris
2 from sklearn.cluster import KMeans
3 from sklearn.decomposition import PCA
4 from sklearn.metrics import silhouette_score, davies_bouldin_score, calinski_harabasz_score
5 import pandas as pd
6
7 # Cargar dataset
8 data = load_iris()
9 X = pd.DataFrame(data.data, columns=data.feature_names)
10
11 # Clustering
12 kmeans = KMeans(n_clusters=3, random_state=42)
13 labels = kmeans.fit_predict(X)
14
15 # Métricas
16 sil = silhouette_score(X, labels)
17 db = davies_bouldin_score(X, labels)
18 ch = calinski_harabasz_score(X, labels)
19
20 # PCA
21 pca = PCA(n_components=2)
22 X_pca = pca.fit_transform(X)
23
24 var = pca.explained_variance_ratio_
25
```

## Resultados

Métrica	Interpretación	Resultado
<b>Silhouette</b>	Separación entre clusters	0.58
<b>DBI</b>	Dispersión/separación	0.63
<b>CH</b>	Cohesión interna	425.1

- Los dos primeros componentes retienen **~96%** de la información.
- La separación visual entre clusters es clara.

## Conclusión

Las métricas de evaluación son esenciales para validar modelos no supervisados. K-Means produjo agrupaciones consistentes en el dataset Iris. PCA fue capaz de representar el dataset de manera compacta y visualmente clara. La combinación **clustering + reducción de dimensionalidad** es ideal para análisis exploratorio y segmentación.

## Referencias

Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.). O'Reilly Media.

Han, J., Pei, J., & Kamber, M. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann.

Scikit-learn. (2024). *Metrics and Clustering Documentation*. <https://scikit-learn.org>

OpenAI. (2025). *ChatGPT Data Science Guidance*. <https://platform.openai.com/docs>