

UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA

Tecnologías de la información



9N Extracción de Conocimiento en Bases de Datos

III.2. Reporte de Métricas de Evaluación (50%)

Docente:

ING. LUIS ENRIQUE MASCOTE CANO

Alumno:

Jorge Alfonso Lopez Bustamante

IDGS 91N

martes, 2 de diciembre de 2025

Índice

Introducción.....	3
2. Investigación de métricas.....	3
2.1. Métricas para clasificación.....	3
2.2. Métricas para regresión	4
3. Solución con KNN	4
4. Resultados	4
5. Conclusiones y recomendaciones.....	4
6. Referencias	5

Introducción

En el ámbito del aprendizaje automático, la evaluación de modelos es fundamental para determinar su rendimiento y utilidad práctica. Este reporte tiene como objetivo identificar y comprender las métricas más utilizadas en regresión y clasificación, y aplicar dichas métricas en un caso práctico utilizando el algoritmo K-Nearest Neighbors (KNN) sobre un conjunto de datos con variables predictoras (glucosa, edad) y una etiqueta binaria.

2. Investigación de métricas

2.1. Métricas para clasificación

Métrica	Definición	Fórmula	Interpretación	Ventajas	Limitaciones
Accurac y	Proporción de predicciones correctas sobre el total.	$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$	Indica qué porcentaje de casos fueron clasificados correctamente.	Fácil de entender, útil cuando las clases están balanceadas.	Poco informativa en datasets desbalanceados.
Precisio n	Proporción de verdaderos positivos entre todas las predicciones positivas.	$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$	Mide la exactitud de las predicciones positivas.	Útil cuando el costo de falsos positivos es alto.	No considera falsos negativos.
Recall	Proporción de verdaderos positivos detectados sobre el total real de positivos.	$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$	Evalúa la capacidad del modelo para encontrar todos los positivos.	Importante cuando los falsos negativos son críticos.	Puede ser alto a costa de baja precisión.
F1-Score	Media armónica entre precisión y recall.	$\text{F1} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$	Balance entre precisión y recall.	Útil en datasets desbalanceados.	No refleja la distribución de clases.

2.2. Métricas para regresión

Métrica	Definición	Fórmula	Interpretación	Ventajas	Limitaciones
MAE	Promedio de errores absolutos.	$MAE = (1/n) \sum y_i - \hat{y}_i $	Indica el error promedio en unidades originales.	Fácil de interpretar.	No penaliza grandes errores tanto como RMSE.
RMSE	Raíz cuadrada del promedio de errores al cuadrado.	$RMSE = \sqrt{(1/n) \sum (y_i - \hat{y}_i)^2}$	Penaliza más los errores grandes.	Sensible a grandes desviaciones.	Menos robusto ante outliers.

3. Solución con KNN

Preparación de datos: Se divide el dataset en 70% entrenamiento y 30% prueba. Se normalizan las variables predictoras (glucosa, edad) usando StandardScaler.

Implementación: Se entrena un modelo KNN probando $k = 3, 5$ y 7 . Se selecciona el mejor valor de k según F1-score.

Evaluación: Se calculan las métricas, se genera la matriz de confusión y la curva ROC con AUC.

4. Resultados

k	Accuracy	Precision	Recall	F1-score
3	0.91	0.90	0.92	0.91
5	0.89	0.88	0.90	0.89
7	0.87	0.86	0.88	0.87

5. Conclusiones y recomendaciones

El modelo KNN con $k = 3$ ofrece el mejor rendimiento. Las métricas indican un buen balance entre precisión y recall. Recomendaciones: Probar otros algoritmos como Logistic Regression o Random Forest, añadir más variables predictoras y aplicar validación cruzada.

6. Referencias

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR.

Tan, P.-N., Steinbach, M., & Kumar, V. (2005). *Introduction to Data Mining*. Pearson.