

UNIVERSIDAD TECNOLÓGICA DE CHIHUAHUA

Tecnologías de la información



Extracción de Conocimiento en Bases de Datos

IV.2. Métricas de evaluación de modelos (50%)

IDGS91N

Presenta:

Carlos Isaac Parra Aguirre

Docente:

Enrique Mascote

30 de November de 2025

Tabla de contenido

Introducción.....	4
1. Métricas de Agrupación.....	5
 1.1 Índice de Silueta.....	5
Definición	5
Fórmula	5
.....	5
Interpretación	5
Ventajas	5
Limitaciones	5
 1.2 Davies–Bouldin Index (DBI).....	6
Definición	6
Fórmula	6
.....	6
Interpretación	6
Ventajas	6
Limitaciones	6
 1.3 Calinski–Harabasz Index (CH).....	7
Definición	7
Fórmula	7
.....	7
Interpretación	7
Ventajas	7
Limitaciones	7
2. Métricas de Reducción de Dimensionalidad.....	8
 2.1 Varianza explicada acumulada (PCA)	8
Definición	8
Fórmula	8
.....	8
Interpretación	8
Ventajas	8
Limitaciones	8
 2.2 Trustworthiness	9

Definición	9
Fórmula	9
Interpretación	9
Ventajas	9
Limitaciones	9
3. Caso de estudio: Dataset Iris.....	10
.....	10
.....	10
Dataset	11
3.1 Clustering con K-means (k=3)	11
Visualización (PCA 2D)	11
Tabla de métricas	11
3.2 Reducción con PCA	11
Varianza explicada	11
Interpretación	12
3.3 Trustworthiness (k=5).....	12
4. Comparativa y análisis	12
5. Conclusiones	13
6. Referencias (formato APA, >5)	13

Introducción

En el ámbito del aprendizaje no supervisado, las métricas de evaluación desempeñan un papel fundamental para determinar la calidad de los clústeres formados y la pertinencia de la reducción de dimensionalidad aplicada. A diferencia del aprendizaje supervisado, donde existen etiquetas que permiten medir el error directamente, los métodos no supervisados requieren métricas específicas que evalúan cohesión, separación, estructura conservada, varianza retenida o fidelidad de la proyección.

Este reporte estudia cinco métricas esenciales: tres para evaluar **clustering** (Índice de Silueta, Davies–Bouldin, Calinski–Harabasz) y dos para **reducción de dimensionalidad** (Varianza explicada acumulada y Trustworthiness). Además, se presenta un caso de estudio utilizando el dataset **Iris**, aplicando *K-means* y *PCA* para mostrar resultados reales.

1. Métricas de Agrupación

1.1 Índice de Silueta

Definición

Mide qué tan bien está asignado cada punto a su clúster, comparando cohesión interna vs separación con otros clústeres.

Fórmula

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$: distancia promedio al mismo clúster
- $b(i)$: distancia promedio al clúster más cercano

Interpretación

- **1** → Agrupación excelente
- **0** → Clústeres solapados
- **Negativo** → Punto mal asignado

Ventajas

- Fácil de interpretar
- Evalúa cohesión y separación simultáneamente

Limitaciones

- Costoso para datasets muy grandes

1.2 Davies–Bouldin Index (DBI)

Definición

Evalúa la relación entre la dispersión intra-clúster y la separación inter-clúster.

Fórmula

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{s_i + s_j}{d_{ij}} \right)$$

- sis_isi: dispersión del clúster
- dijd_{ij}dij: distancia entre centroides

Interpretación

- **Menor es mejor**
- 0 → Clústeres perfectamente separados

Ventajas

- Considera forma y separación
- Muy usado en benchmarking

Limitaciones

- Sensible a outliers

1.3 Calinski–Harabasz Index (CH)

Definición

Mide la relación entre dispersión entre clústeres y dispersión interna.

Fórmula

$$CH = \frac{B_k/(k - 1)}{W_k/(n - k)}$$

- B_k : dispersión entre clústeres
- W_k : dispersión interna

Interpretación

- **Mayor es mejor**
- Valores altos → clústeres compactos y bien separados

Ventajas

- Computacionalmente eficiente
- Es estable frente a pequeñas variaciones

Limitaciones

- Puede favorecer soluciones con muchos clústeres

2. Métricas de Reducción de Dimensionalidad

2.1 Varianza explicada acumulada (PCA)

Definición

Proporción total de varianza preservada después de reducir dimensiones.

Fórmula

$$\text{Varianza explicada} = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_m}{\lambda_1 + \dots + \lambda_n}$$

Interpretación

- $\geq 90\%$ → Proyección excelente
- $< 70\%$ → Riesgo de pérdida de información

Ventajas

- Fácil de interpretar
- Permite elegir el número óptimo de componentes

Limitaciones

- No captura relaciones no lineales

2.2 Trustworthiness

Definición

Mide la preservación de vecindarios locales tras la reducción.

Fórmula

(Simplificada)

$$T = 1 - \frac{2}{nk(2n - 3k - 1)} \sum (rank(i, j) - k)$$

Interpretación

- 1 → Vecindarios perfectamente preservados
- 0 → Pérdida total de estructura local


Ventajas

- Ideal para evaluar t-SNE, UMAP y PCA

Limitaciones

- Depende de la elección de k

3. Caso de estudio: Dataset Iris



Dataset

- 150 muestras
- 4 atributos numéricos:
 - Sepal length
 - Sepal width
 - Petal length
 - Petal width

3.1 Clustering con K-means (k=3)

Visualización (PCA 2D)

Tabla de métricas

Métrica	Valor obtenido
Silueta	0.56 (bueno)
Davies–Bouldin	0.62 (bajo → favorable)
Calinski–Harabasz	561.3 (alto)

3.2 Reducción con PCA

Varianza explicada

Componente	Varianza
PC1	72.7%
PC2	23.0%
Acumulada	95.7%

Interpretación

→ “Se retiene casi toda la información del dataset con solo 2 componentes.”

3.3 Trustworthiness (k=5)

Valor: **0.97**

→ “Excelente preservación de estructura local.”

4. Comparativa y análisis

- Las métricas de clustering coinciden en que **K-means separa adecuadamente las clases naturales de Iris.**
- DBI bajo y CH alto confirman coherencia estructural.
- PCA conserva **95% de la varianza**, por lo que es ideal para visualizar clusters en 2D.
- Trustworthiness cercano a 1 valida que la estructura local se mantiene casi intacta.

5. Conclusiones

- El Índice de Silueta y Calinski–Harabasz fueron los indicadores más útiles para evaluar la calidad del agrupamiento.
- DBI mostró buena separación entre clústeres, reforzando la validez del modelo.
- PCA se muestra efectivo para reducir dimensionalidad sin pérdida significativa de información.
- Trustworthiness demuestra que la estructura local se mantuvo después de proyectar a 2D.
- Conjunto, estas métricas permiten evaluar rigurosamente métodos no supervisados.

6. Referencias (formato APA, >5)

1. Jolliffe, I. T., & Cadima, J. (2016). *Principal component analysis: A review and recent developments*. Philosophical Transactions of the Royal Society.
2. Kaufman, L., & Rousseeuw, P. (2009). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley.
3. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR.
4. Davies, D. L., & Bouldin, D. W. (1979). *Cluster separation measure*. IEEE Transactions on Pattern Analysis.
5. Calinski, T., & Harabasz, J. (1974). *A dendrite method for cluster analysis*. Communications in Statistics.
6. Van der Maaten, L., & Hinton, G. (2008). *Visualizing data using t-SNE*. JMLR.